Análise de clusteres dos jogadores de futebol do time Audax Rio de Janeiro Esporte Clube

Rodrigo Caldiron - RA 185416

1 Introdução

Audax Rio de Janeiro Esporte Clube é um time brasileiro de futebol que foi fundado em 8 de maio de 2005. No começo do ano de 2024, a agremiação esportiva participou do Campeonato Carioca de Futebol, o qual é composto por doze equipes e, consequentemente, por onze rodadas. Além disso, nesse mesmo período, Audax jogou apenas um jogo contra a Portuguesa-RJ na Copa do Brasil, e acabou sendo eliminado da competição apesar do empate. O time realizou 41 jogos-treino no decorrer da sua campanha.

Nesse sentido, foram coletadas 102 variáveis referentes aos 53 jogos citados para cada jogador através da tecnologia da Catapult Sports, que basicamente monitora o desempenho dos jogadores por meio de GPS. Tais informações foram disponibilizadas e autorizadas para uso pelo preparador físico daquela época, Luiz Carlos Caldiron [8], e podem ser acessadas pelo GitHub. Vale ressaltar que o goleiro não foi utilizado para essa análise, já que é a posição que se menos movimenta em comparação com as demais, e que o banco de dados não apresenta dados faltantes. Por fim, escolheu-se trabalhar com as seguintes variáveis:

- PlayerName: nome do jogador;
- Position: posição do jogador, dentre elas: zagueiro, lateral, volante, meia, atacante e extrema;
- Dist: distância total que o jogador percorreu (km);
- SprintDistance (SD): distância total que o jogador percorreu considerando que o mesmo fez um tiro acima de 24 km/h (m);
- Sprints: quantidade de piques que o jogador realizou com uma velocidade acima de 24 km/h;
- Accelerations (ACC): quantidade de acelerações que o jogador realizou;
- Decelerations (DEC): quantidade de desacelerações que o jogador realizou;
- Energy: gasto energético do jogador (kcal);
- Impacts: quantidade de vezes que o jogador recebeu um impacto equivalente a cinco vezes seu peso corporal;
- TopSpeed: maior velocidade atingida pelo jogador (km/h).

Sendo assim, o conjunto de dados final exigiu duas condições, a primeira que é o agrupamento por nome de jogador com suas estatísticas médias nos 53 jogos, totalizando 28 jogadores, onde dois ocupam a posição de atacante, quatro são laterais e extremas, cinco são meias, seis zagueiros e sete são volantes. Enquanto a segunda condição filtrou jogadores que jogaram por pelo menos 90 minutos, para ter a garantia de eles terem jogado os dois tempos regulamentares, e assim, impedindo possíveis outliers. Diante disso, neste trabalho há o objetivo de clusterizar os jogadores do Audax no que se refere às suas posições com o auxílio das variáveis supracitadas.

2 Materiais e Métodos

Toda a análise estatística foi realizada através do software R [7] com o auxílio dos seguintes pacotes: readr na leitura da base de dados, GGally no gráfico de dispersão, mclust para realizar a clusterização, e por último, covRobust na identificação de outliers no método do vizinho mais próximo [5]. Exceção das Figuras 12 e 13 que foram geradas pelo próprio aplicativo da Catapult Sports.

2.1 Conjunto de dados

Como dito anteriormente, foi usado a média aritmética simples como tentativa de representar as estatísticas dos jogadores. No entanto, no decorrer da análise, percebeu-se que o número de jogos entre os jogadores variava muito, e, portanto, optou-se por utilizar o estimador alisado de Devore [1] com a intenção de deixar a comparação mais justa possível, que foi computado da seguinte maneira:

$$\text{MediaNova[i]} = \text{W[i]} \cdot \text{A[i]} + (1 - \text{W[i]}) \cdot \text{S} \tag{1}$$

onde
W[i] $= \frac{\text{M[i]}}{\text{M[i]+AVG}}$;
M[i] é o número de jogos do jogador i, i $= 1, 2, \ldots, 28$;
AVG é a média aritmética simples de todos os jogos dos jogadores;
A[i] é a média aritmética simples do jogador i respectivo à variável j, $j = 1, 2, \ldots, 8$;
S é a média aritmética simples de todos os jogadores respectivo à variável j.

2.2 Agrupamento baseado em modelo

Será empregado para agrupamento dos jogadores o algoritmo EM [2], que pode ser visto como um processo iterativo de dois passos até a convergência, o primeiro passo possui a letra E pois ele toma o valor esperado da função logarítmica da verossimilhança completa, ou seja, ele computa a probabilidade a posteriori do i-ésimo jogador pertencer respectivamente ao i-ésimo grupo. Tal cálculo é extremamente importante, já que há uma densidade estimada para cada etiqueta, ou seja, a observação não é apenas colocada ao grupo de forma determinística, como era de costume em métodos anteriores, Clustering Hierárquico, por exemplo. Já o segundo passo M maximiza essa função com a intenção de gerar novas estimativas para os parâmetros do modelo, em que a matriz de variância e covariância $\mathbf{\Sigma}$ dependerá intrinsecamente deles. Afinal, já existem modelos tabulados [3] com sua distribuição, volume, forma, orientação rotacional e quantidade de parâmetros.

Ademais, é necessário que as variáveis citadas na Introdução sejam conjuntamente normais dado as formações dos clusteres, e para averiguar isso, foi feita uma análise exploratória através da função pairs. Infelizmente, o pressuposto de normalidade não foi atingido (Figura 7) e precisou utilizar uma distribuição T de Student multivariada para acomodar os possíveis outliers que fazem ter as caudas pesadas. No entanto, mesmo assim foram feitas comparações entre essas duas distribuições. Testes de hipóteses para normalidade não foram cogitados para evitar falsas descobertas.

Para lidar com os candidatos a outliers, que são observações que destoam da grande maioria das demais, foi aplicado o método de vizinhos mais próximos. O algoritmo se baseia na adição de 5% de outliers artificiais uniformemente distribuídos. Por meio do metaparâmetro $k = 12$ vizinhos mais rentes, ele ajusta um modelo de mistura com duas componentes: a primeira para dados agrupados, e a segunda para os outliers. Vale ressaltar que o número de observações aberrantes podem variar dependendo do modelo ajustado.

2.3 Critério para seleção do número de clusteres

O método utilizado para selecionar a quantidade de clusteres foi através do Bayesian Information Criterion (BIC), onde geralmente se escolhe o modelo que apresenta o maior valor de BIC, apesar de talvez ser um máximo local, já que ele tenta harmonizar tanto a quantidade de parâmetros do modelo, responsável pela sua complexidade, quanto o ajuste do modelo baseado na função de verossimilhança.

2.4 Extração de atributos

Utilizou-se para identificação de características a Análise de Componentes Principais (do inglês, PCA), visto que haviam oito variáveis, e para obter a interpretação geométrica desse agrupamento era necessário diminuir a dimensão do problema para $\mathbb{R}^2$. Nota-se que existe um nuance de garantir que após escrevermos nossas novas variáveis Y_i como sendo combinação linear das demais através dos loadings, ou seja, da correlação de cada uma com cada componente principal, que o pressuposto da distribuição adotada, no caso a T de Student multivariada permaneça, como na Figura 2.

3 Resultados

Houve uma tentativa de aplicar transformações nas variáveis da Figura 1, com a intenção de alcançar normalidade, em específico, o logaritmo em Energy e SD, uma vez que eram as que assumiam valores maiores, entretanto, a diferença foi irrisória. Nota-se que na Figura 2 foi considerado apenas as quatro primeiras componentes principais para verificar se manteve a distribuição T de Student, pois juntas explicavam 95% da variabilidade total.

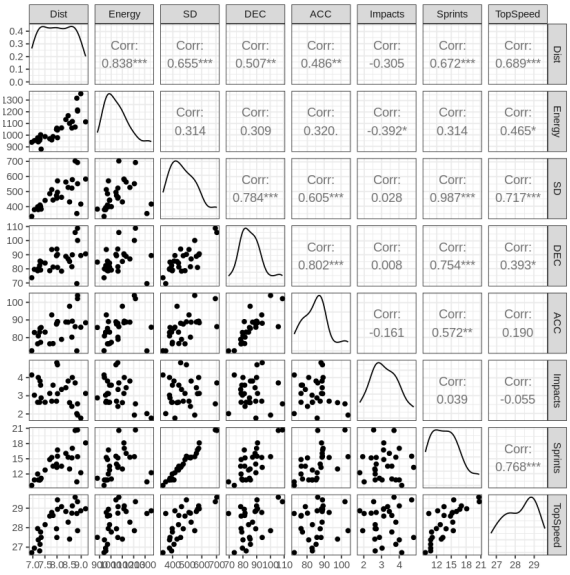


Figura 1: Gráfico ggpairs.

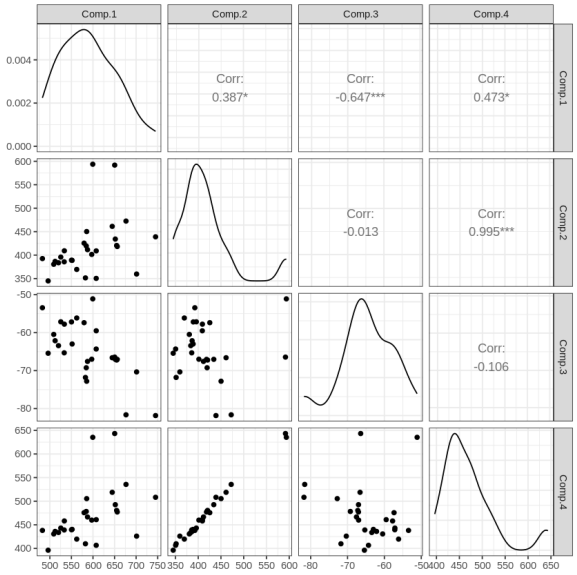


Figura 2: Gráfico ggpairs após PCA.

Sabendo que agora é possível de realizar a PCA, temos na Figura 3 a confirmação da variabilidade total acumulada de forma significativa até a quarta componente. Por meio da Figura 4, observa-se que todas as variáveis, exceto Impacts, apresentam altos valores da Componente 1, ao passo que maiores valores da Componente 2 estão associados com maior gasto energético e impactos, este último em módulo. Visualmente, zagueiros não estão familiarizados em realizar muitas atividades que exigem velocidade, como SD, sprints, acelerações, entre outras. Estas aparentam estar mais presentes em posições como laterais, meias e volantes, além disso, atacantes e extremas parecem estar próximos entre si.

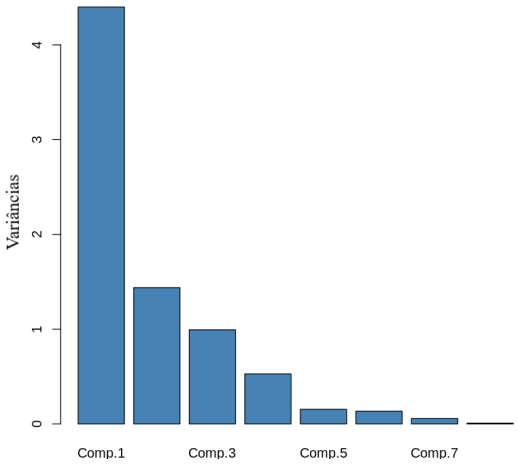


Figura 3: Screeplot da PCA.

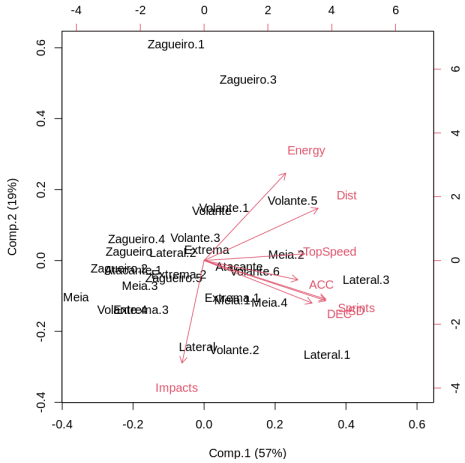


Figura 4: Biplot das duas primeiras componentes principais.

Através da Figura 5 é possível ver que o modelo VEV apresenta o maior BIC, assim, foi escolhido o modelo que possui volume variado entre os clusteres, uma razão igual dos volumes-entre-dimensões, isto é, os autovalores entre os clusteres, enquanto a orientação dos eixos, que são os autovetores, variados. Apesar da Figura 6 ter os maiores valores do BIC para clusteres de tamanho zero, há o interesse de agrupar os jogadores, e não apenas ter ruídos, então, cogitou-se por escolher o modelo VEV de tamanho 2, já que apresenta o maior valor BIC considerando clusteres de tamanhos maiores do que 1.

De certa forma, a escolha do modelo é adequada, e não é parcialmente incorreta, antes fosse caso existisse a letra I na segunda componente, indicando que a razão volumes-entre-dimensões é isométrica dentro do cluster, o que não é verdade, pois existem variáveis que assumem valores altos, enquanto outras são pequenas. Existiu a ideia de utilizar o Integrated Complete Likelihood (ICL), visto que esse critério geralmente favorece modelos com número baixo de clusteres, pelo fato dele penalizar tamanhos maiores de grupos se comparado ao BIC, porém os resultados foram os mesmos para ambas distribuições.

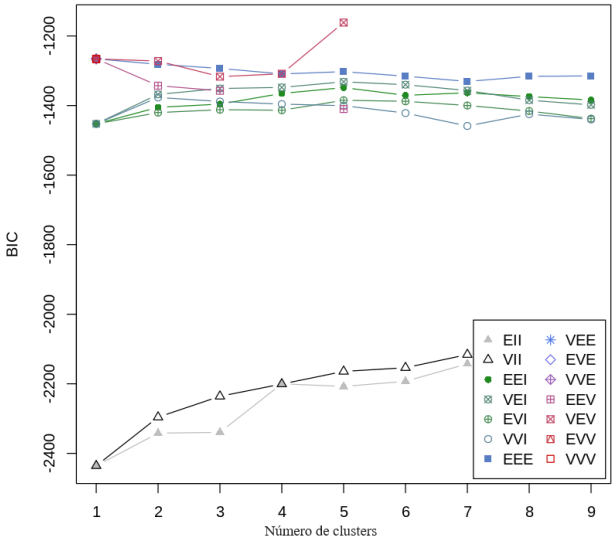


Figura 5: BIC considerando normalidade.

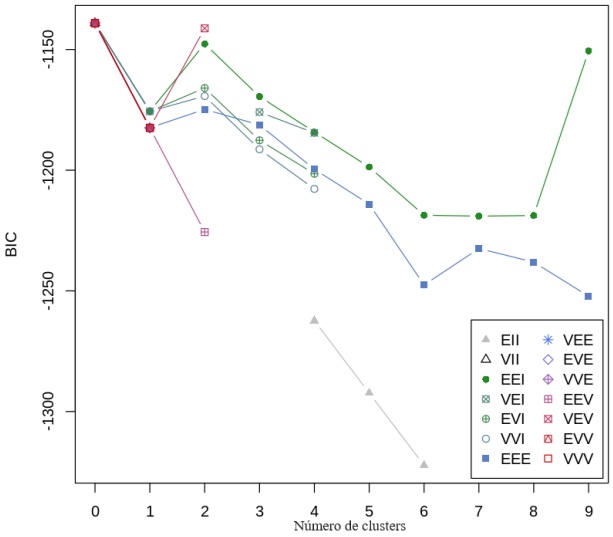


Figura 6: BIC considerando T de Student.

Na Figura 7 foi preciso utilizar o metaparâmetro scale da priori, que é a matriz de covariância, porque somente assim foi possível verificar as elipses, ainda que inadequadas. Outro motivo para escolher esse método bayesiano foi que anteriormente havia um cluster com só um jogador, logo, evitou-se uma degeneração. A Figura 8 ilustra uma abordagem mais adequada considerando um cluster separado somente para os outliers. O pacote covRobust suspeitava a existência de seis outliers, e esse número passou para onze com a escolha do modelo VEV. Sem dúvidas é um número muito grande de dados aberrantes considerando um conjunto de 28 observações.

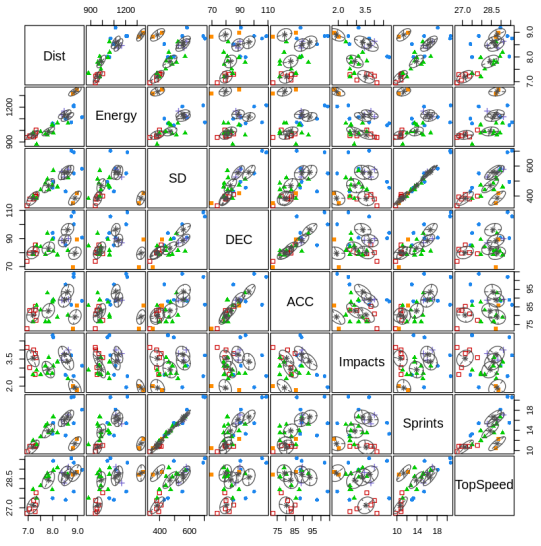


Figura 7: Classificação do modelo de normalidade.

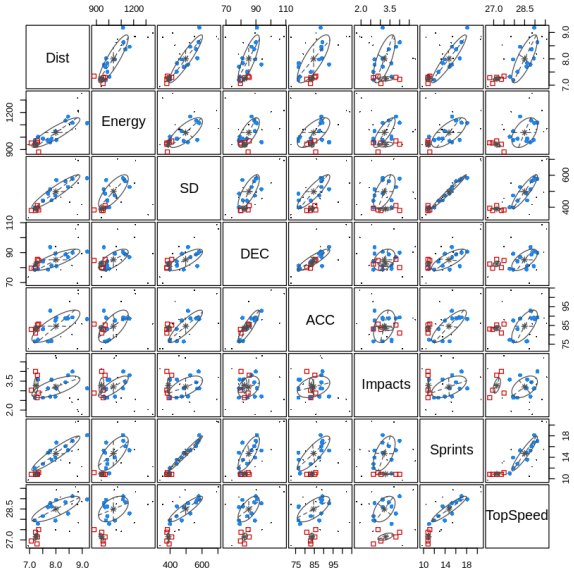


Figura 8: Classificação do modelo T de Student.

Perceba que na Figura 9, observações com maior incerteza, considerando um percentil de 95%, são destacadas com círculos grandes, e as observações com incerteza maior que o percentil 75% são marcadas com círculos pequenos. É similar ao gráfico de Silhouette na seguinte analogia, caso a silhueta do i-ésimo jogador é próxima de zero, esse jogador está na fronteira de dois clusteres, se o valor é aproximadamente -1, o jogador está no cluster incorreto, podendo ser na fronteira do seu próprio cluster, essas duas situações produzem círculos grandes de incerteza, devido à ambiguidade da locação do jogador. Supondo que a silhueta assume um valor próximo de 1, o jogador está no cluster correto, e o círculo será menor.

A Figura 10 contêm as incertezas individuais, com o acúmulo de incerteza no eixo y. A interpretação é que existe uma probabilidade de 0.025 da observação estar em outro cluster, e a probabilidade complementar de 0.975 de estar no atual. É mais fácil de interpretar nesta situação, porque existem dois clusteres, enquanto o terceiro está pré-definido, que são os ruídos.

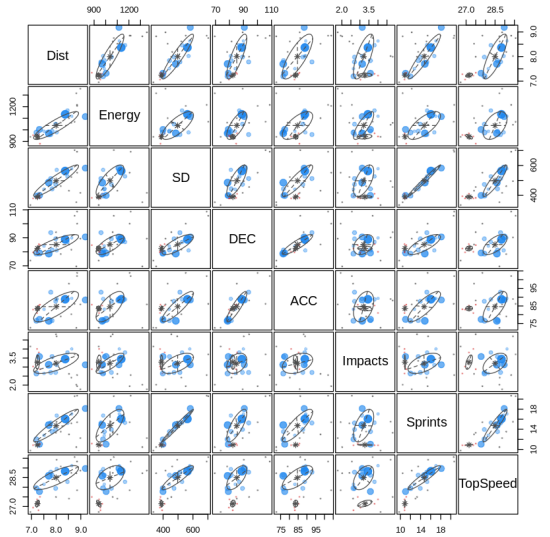


Figura 9: Incerteza das observações modelo T de Student.

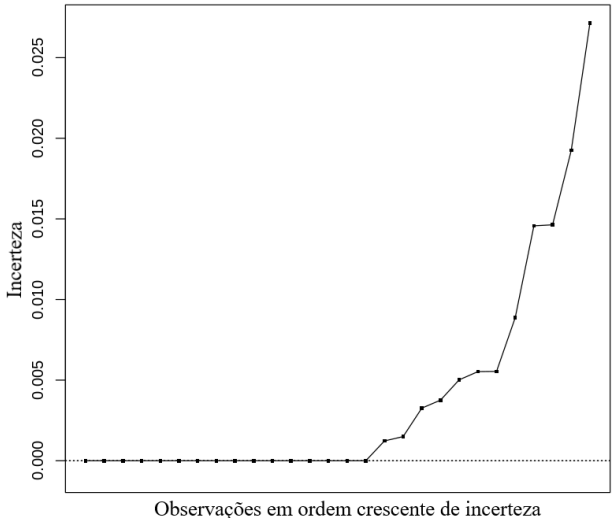


Figura 10: Incerteza individual modelo T de Student.

Foi necessário padronizar as variáveis depois de agrupadas para visualizar melhor os perfis da Figura 11.

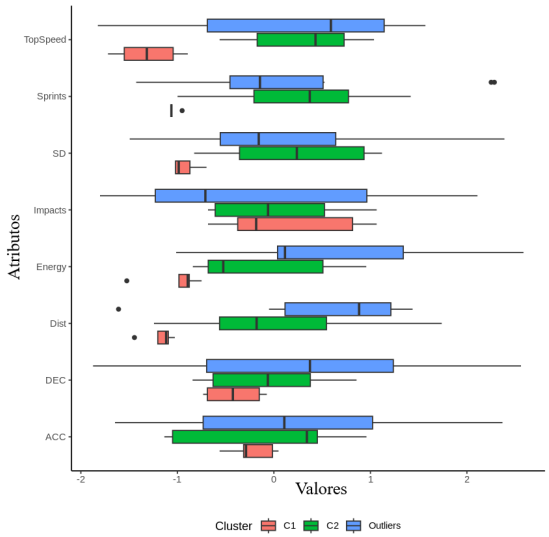


Figura 11: Análise de perfis.

As Figuras 12 e 13 são referentes à movimentação de um volante (membro exemplar do grupo dos ruídos) no jogo contra o Flamengo na Arena da Amazônia, em Manaus. O gráfico de calor na cor vermelha representa a região que o jogador esteve por mais tempo, enquanto tonalidades mais fracas dizem o contrário. Por conseguinte, o mesmo raciocínio é feito na Figura 13, mas agora a tonalidade mais forte é devido à velocidade do jogador.

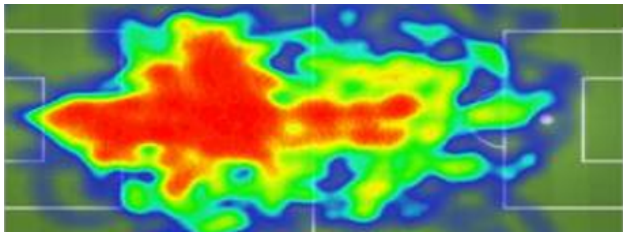


Figura 12: Gráfico de calor de um volante.

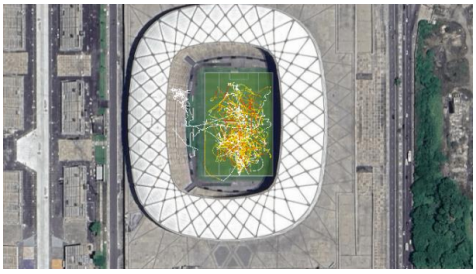


Figura 13: Satélite Arena da Amazônia.

As médias de cada variável de cada cluster são mostradas a seguir:

Tabela 1: Médias das variáveis para cada cluster.

Cluster	Dist	Energy	SD	DEC	ACC	Impacts	Sprints	TopSpeed
1	7.2426	940.2785	389.2521	82.4487	83.5993	3.2740	10.8947	27.1549
2	7.9991	1036.9385	497.8165	85.1921	84.5843	3.2064	14.7191	28.4979
Outliers	8.4130	1129.8527	492.4171	88.7891	87.0229	3.0942	14.5078	28.4741

Tabela 2: Frequências das posições do Cluster 1.

Posição	Frequência
Zagueiro	2
Lateral	0
Meia	1
Volante	1
Atacante	0
Extrema	1

Tabela 3: Frequências das posições do Cluster 2.

Posição	Frequência
Zagueiro	2
Lateral	1
Meia	3
Volante	1
Atacante	2
Extrema	3

Tabela 4: Frequências das posições do grupo dos outliers.

Posição	Frequência
Zagueiro	2
Lateral	3
Meia	1
Volante	5
Atacante	0
Extrema	0

4 Discussão

Com base na Figura 11 e nas Tabelas acima, temos que o Cluster C1 apresenta os menores valores para todos os atributos, com exceção aos impactos. O interessante é que este grupo é formado por cinco jogadores, onde quatro deles jogaram um único jogo, esse fato talvez possa justificar o mal desempenho dos mesmos, pela falta de oportunidade de mostrarem seus talentos em outros jogos. O grupo C2 é tipicamente formado por jogadores com posições do ataque, marcados por uma maior distância se baseada em uma velocidade acima de 24 km/h, logo, fazem mais sprints e assumem velocidades maiores se comparado ao grupo dos outliers, constituído por jogadores da defesa, que percorrem uma distância total maior, assim como o número de acelerações e desacelerações, portanto, fazendo com que o gasto energético seja maior.

Em vista disso, há um nível de satisfação com o objetivo proposto sobre a clusterização dos jogadores, pois esperava-se descondensar as posições na formação de dois grupos, caracterizadas pela defesa e pelo ataque.

Referências

[1] Gelman, A., Carlin, J. B., Stern, H. S., & Rubin, D. B. (1995). Bayesian data analysis. Chapman and Hall/CRC.

[2] Relvas, Carlos Eduardo Martins. Agrupamento baseado em modelos de mistura de gaussianas com covariáveis [tese]. São Paulo: , Instituto de Matemática e Estatística; 2020 [citado 2024-05-25]. doi:10.11606/T.45.2020.tde-16012021-193220.

[3] C. Bouveyron, G. Celeux, T. Brendan Murphy e A. E. Raftery. Model-Based Clustering and Classification for Data Science. Cambridge University Press, 2019. 10.1017/9781108644181.

[4] B. S. Everitt, S. Landau, M. Leese e D. Stahl. Cluster Analysis, 5th edition. John Wiley & Sons, 2011.

[5] Raftery AE, Wang N. Nearest Neighbor Variance Estimation (NNVE): Robust Covariance Estimation via Nearest Neighbor Cleaning. Seattle: University of Washington, Department of Statistics; 2000. Disponível em: aqui. Acessado em 26/05/2024.

[6] Slides da disciplina ME921 do professor Guilherme Vieira Nunes Ludwig.

[7] R Core Team (2023). R: A Language and Environment for Statistical Computing. R Foundation for Statistical Computing, Vienna, Austria. https://www.R-project.org/.

[8] Caldiron LC. https://luizcarloscaldiron.com.br/. Acessado em 27/05/2024